



西南大学 商贸学院

Business College of Southwest University

学年设计II文档

题 目	重庆市二手房源价格数据分析与智能可视化系统
学号、姓名、班级	张浩博
学号、姓名、班级	
学号、姓名、班级	
指导教师	
成 绩	
完成时间	2026 年 6 月

目录

[[TOC]]

摘要

本项目围绕重庆市二手房挂牌价数据的获取、治理、分析与展示，完成了一套轻量化后台管理式数据产品。系统以 MySQL 8.x 为唯一运行数据库，后端采用 Flask 分层 API，前端采用 React、TypeScript 与 Vite，图表由 Recharts 和 ECharts 共同完成，数据分析使用 scikit-learn，智能问数与报告生成接入 DeepSeek。与一次性爬取后静态画图的方案相比，本项目更重视数据来源说明、增量快照、质量监控、模型证据和 Agent 工具调用记录，形成“数据源—采集任务—清洗入库—增量维护—分析建模—可视化—智能报告”的闭环。

截至 2026 年 6 月 18 日，业务库共有 122,316 条有效房源，覆盖 38 个区县，其中旧库冷启动数据 121,777 条，新系统房天下标准采集数据 539 条；快照表共有 122,317 条记录。最新分析任务采用按区县分层、固定顺序抽样的 5,000 条样本，覆盖全部 38 个有效区县和 3 类来源。随机森林回归的 MAE 为 1166.21 元/平方米、RMSE 为 1598.61 元/平方米、 R^2 为 0.7105；KMeans 轮廓系数为 0.2848；IsolationForest 与强规则联合识别 123 条异常样本，异常率为 2.46%。

系统已通过 Python 语法检查、34 项后端自动化测试和前端生产构建，并使用真实业务库完成 Dashboard、采集任务、分析建模等页面验收。DeepSeekAgent 已保存 25 条工具调用和 5 份报告。本文只将上述结果表述为对挂牌价的描述、解释和辅助估计，不将其等同于成交价，也不把冷启动旧数据描述为新系统实时采集数据。部署工作在本轮暂缓，文中仅给出后续部署方案。

关键词：重庆二手房；挂牌价；增量快照；数据质量；机器学习；智能问数

第 1 章 概述

1.1 项目背景

重庆市辖区范围广，不同区县在产业结构、交通条件、公共服务、建设年代和住房供给上存在明显差异。公开房源平台能够持续产生二手房挂牌信息，但不同平台字段命名、单位、页面结构和反爬策略不一致，同一房源还会出现重复展示、价格变化、状态变化和短期下架等情况。如果只把一次采集结果保存为 CSV，再制作若干静态图表，数据很快失去时效，也无法说明模型结论来自哪一批样本。

学院指导手册要求数据不少于 5 万条，完成清洗整理与存储，支持定期增量更新，以 Web 或 App 展示可视化，并使用挖掘算法得到相关结论。项目因此把重点从“爬多少数据”扩展为“如何形成可信、可维护、可展示的数据系统”。最终实现不仅包含采集脚本和图表，还包含任务状态、失败日志、唯一指纹、价格快照、质量报告、分析任务、模型结果和 Agent 工具证据。

1.2 研究对象与口径

本项目研究对象是公开页面中的重庆市二手房挂牌价或报价。挂牌价反映业主和中介在特定时间点的市场预期，能够用于区域比较、结构分析和异常识别，但不能直接等同于真实成交价。系统前端、接口、报告和本文统一使用“挂牌价”“挂牌单价”“挂牌总价”等表述，避免因概念混用而夸大结论。

数据由两层构成：第一层是旧项目 SQLite 数据导入形成的冷启动基线，用于达到课程要求的数据规模并提供区县覆盖；第二层是当前系统通过房天下等来源采集的标准化增量数据，用于证明采集、去重、last_seen_at 更新、价格快照和失败日志链路。两层数据都进入 MySQL，但通过 source 字段保留来源，分析结果同时记录来源分布，防止把 12 万条历史样本描述成新系统实时抓取。

1.3 项目目标

数据目标是构建字段统一、来源可追踪、数量超过 5 万条的重庆二手房挂牌价数据底座；工程目标是实现可查询、可采集、可分析、可问数的前后端系统；研究目标是使用描述统计、回归、聚类 and 异常检测回答区域差异、价格驱动因素、市场分层和异常挂牌等问题；展示目标是让答辩教师能够通过页面、数据库记录、任务日志和测试命令核验系统功能。

项目坚持最小但完整的交付原则。第一版不引入微服务、复杂权限中心或大数据集群，而是使用 Flask、MySQL 和 React 完成全链路；部署不作为本轮完成条件，避免在核心数据与文档尚未收口时分散精力。功能完成后再补充一键启动脚本、增量验收脚本、验收证据导出脚本和正式文档生成脚本，降低后续复现成本。

1.4 主要成果与创新点

第一，系统把采集过程建模为可持久化任务，记录 pending、running、success、

partial_failed 等状态以及成功页、失败页、解析条数和错误类型，使反爬波动不再只是终端中的临时错误。第二，唯一指纹不包含价格，同一房源的价格变化会更新主表并写入 snapshot，而不是重复新增房源。第三，分析任务由“最近 N 条”改为按区县分层的确定性抽样，显著降低只覆盖少数区县造成的选择偏差。

第四，异常检测不直接把 IsolationForest 的所有孤立样本都当成错误，而是结合区县中位数偏离、Z 分数和强规则给出异常理由，并把异常记录保留供复核。第五，Agent 不直接连接 MySQL，也不执行用户输入 SQL，而是调用 ToolRegistry 中的白名单工具；具体数值来自工具 JSON，工具参数、结果和耗时保存到 agent_tool_calls，报告证据保存到 generated_reports.evidence_json。

第 2 章 系统分析和可行性分析

2.1 学院要求映射

表 2-1 学院要求与系统实现映射

学院要求	系统实现	真实证据	状态
不少于 5 万条	MySQL listings 统一存储	有效 122,316 条，38 区县	完成
数据清洗整理	字段解析、标准化、质量分与异常标记	可分析 122,288 条	完成
定期增量	APScheduler 注册、手动增量接口、指纹 upsert	重复采集 153 条未变；真实价格变化 1 条	代码完成，常驻暂缓
Web 可视化	Dashboard、房源、任务、质量、模型、Agent	真实后端页面截图	完成
挖掘结论	回归、KMeans、IsolationForest	$R^2=0.7105$ ，异常率=2.46%	完成
稳定美观	统一异常响应、任务日志、科研简约界面	34 项测试、构建和浏览器检查	完成

映射结果表明，部署暂缓并不影响学院对数据、清洗、增量、可视化和挖掘的核心要求。需要明确的是，“定期更新”在非部署环境中无法通过服务器连续运行数天来证明，因此本轮采用三类证据：调度器注册逻辑和接口测试、手动触发增量任务、重复采集与价格变化的数

数据库结果。后续上线后再开启 `SCHEDULER_ENABLED` 和增量任务开关。

说明书、安装使用说明、设计日志和答辩证据清单分别生成，避免将所有内容堆在一份文档中。主说明书保留项目背景、分析设计、实现过程、关键代码、问题解决和总结展望；安装文档给出环境变量、数据库初始化和启动流程；日志按日期记录可核验活动；证据清单逐项标明截图或命令位置。

2.2 功能需求

系统用户以课程答辩和研究演示为主，核心操作包括登录后台、查看总体指标和区县图表、按条件检索房源、创建小规模采集任务、查看失败日志、生成质量报告、启动分析任务、查看模型指标和异常房源、向 Agent 提问并导出报告。所有接口返回统一 `code`、`message`、`data` 和 `trace_id`，便于前端提示与错误定位。

房源查询支持 `district`、`price_min`、`price_max`、`area_min`、`area_max`、`keyword`、`page` 和 `page_size`。采集任务支持来源、区县、页数、并发和模式参数。分析任务支持 EDA、回归、聚类、异常检测或 `all`。Agent 支持市场统计、图表序列、采集状态、增量任务、分析任务、模型结果和报告生成等白名单工具，禁止任意 SQL。

2.3 非功能需求

稳定性方面，爬虫单页失败不会中断整个任务，失败页进入日志并允许任务以 `partial_failed` 收口；后端异常通过统一响应返回，前端展示加载态和错误提示。性能方面，常用图表使用数据库聚合与有限样本查询，在 12 万条数据下本机实测均低于 2 秒，其中 `overview` 约 1.02 秒，区县均价约 0.25 秒，价格分布约 0.31 秒。

安全与伦理方面，密钥保存在环境变量或数据库秘密配置中，不写入仓库；Agent 只通过 `ToolRegistry` 访问服务层；爬虫默认低并发、随机间隔，不绕过验证码，不做强对抗反爬；公开数据仅用于课程研究。可维护性方面，后端保持 `api—services—models—crawlers/tasks/ml/agent` 分层，路由不承载复杂 SQL 和模型训练。

2.4 可行性与风险

技术可行性来自成熟的 Python 与 Web 生态。Flask 适合课程项目快速构建 API；SQLAlchemy 与 PyMySQL 能对接 MySQL 8.x；`ThreadPoolExecutor` 足以完成低并发分片

采集；Pandas 与 scikit-learn 可完成特征工程和模型训练；React 与图表库能提供清晰交互。项目无需 GPU 和分布式集群，普通开发电脑即可运行。

主要风险包括页面结构变化、反爬网关、旧数据与新数据口径差异、模型抽样偏差、趋势时间跨度不足和大模型幻觉。对应措施是保留失败 URL 与错误类型、将旧数据标注为 legacy 来源、记录抽样策略与来源分布、只基于真实 snapshot_time 绘制趋势、用工具白名单约束 Agent，并在结论中展示误差指标和数据限制。

第 3 章 系统设计

3.1 总体架构

系统采用前后端分离但部署简单的单体架构。浏览器访问 React 页面，前端通过统一 API 客户端请求 Flask；Blueprint 只负责参数接收和统一响应，Service 处理查询、采集、质量、分析和 Agent 业务，SQLAlchemy 模型映射 MySQL 表。采集任务由爬虫注册表选择具体来源，分析服务调用 scikit-learn，Agent 服务调用白名单工具后再请求 DeepSeek。

数据流从公开房源页面开始，经解析与字段标准化后进入 ListingService.upsert_listing。新房源写主表和初始快照，未变房源只更新 last_seen_at，价格变化更新当前价格并追加快照。Dashboard 从服务层聚合 listings 与 listing_snapshots；分析任务把抽样数据转换为特征矩阵并保存 metrics、artifacts 和 evidence；Agent 工具读取这些聚合结果，不直接暴露数据库。

表 3-1 最终技术栈

层级	主要技术	职责
前端	React + TypeScript + Vite	页面状态、交互、API 调用
图表	Recharts + ECharts	常规统计图与重庆地图
后端	Flask + Blueprint + Service	接口、业务编排、统一响应
数据	MySQL 8.x + SQLAlchemy + PyMySQL	唯一运行数据库与持久化
采集	requests + BeautifulSoup + ThreadPoolExecutor	低并发、多来源、失败日志

层级	主要技术	职责
分析与智能	Pandas + scikit-learn; DeepSeek + ToolRegistry	EDA、回归、聚类、异常检测、问数与报告

3.2 数据库设计

数据库以 listings 为中心，周边表分别记录快照、采集、质量、模型和 Agent 证据。listings 保存当前状态，listing_snapshots 保存时间序列；crawl_tasks 与 crawl_logs 构成任务审计；data_quality_reports 保存一次质量扫描；analysis_jobs 与 model_results 保存训练任务和结果；agent_tool_calls 与 generated_reports 保存智能问答证据。

主表使用 source 与 fingerprint 联合唯一约束。fingerprint 由来源房源标识、规范化链接、标题、区县、小区、面积和户型等稳定字段构成，不包含价格。这样价格变化不会破坏同一性。连续 N 次未出现标记 inactive 的策略在当前有限页补采条件下暂不启用，避免把未覆盖页面中的房源误判为下架。

表 3-2 核心数据表

表名	核心作用	关键证据
listings	标准房源当前状态	122,316 条
listing_snapshots	价格与状态时间快照	122,317 条
crawl_tasks / crawl_logs	任务状态与页级日志	成功、部分失败、拦截原因
data_quality_reports	质量扫描快照	最新报告 #3
analysis_jobs / model_results	模型任务与证据	最新任务 #9
agent_tool_calls	工具参数、结果和耗时	25 条
generated_reports	报告正文与 evidence_json	5 份




图 3-1 MySQL 数据底座验收脚本输出快照

3.3 API 与模块边界

后端入口 `create_app` 负责加载配置、初始化扩展和注册 Blueprint。`api` 目录只做参数转换和返回；`services` 目录集中业务逻辑；`models` 目录定义 ORM；`crawlers` 目录封装数据源；`tasks` 目录负责调度；`agent` 目录封装 ToolRegistry 与 DeepSeek 客户端。该结构使房源查询、采集和模型训练可以分别测试，也避免在路由中拼接复杂 SQL。

接口统一返回 JSON 结构并生成 `trace_id`。健康检查、概览、图表、房源查询、质量、采集、调度、分析、设置和 Agent 均通过 Blueprint 注册。前端 API 客户端负责附加认证 Token、解析错误与类型转换。登录采用课程演示所需的本地管理员 Token，不声称已经接入学校统一身份认证。

统一接口返回示例

```
{
  "code": 0,
  "message": "ok",
  "data": {},
  "trace_id": "20260618-abcdef12"
}
```

3.4 前端信息架构

前端保留现有 React + TypeScript 方案，不为追求与早期需求文档一致而重写为原生

JavaScript。侧边栏包含首页总览、房源数据管理、采集任务管理、数据清洗质量、分析建模、智能问答与报告、系统设置七个模块。页面使用白底、深蓝标题、浅灰分区与少量橙色强调，优先展示真实数据状态而非复杂动效。

Dashboard 负责总体 KPI、区县地图与排行、总价分布、面积—单价散点、快照趋势、户型分布和任务状态。分析页展示 MAE、RMSE、 R^2 、MAPE、特征重要性、箱线图、聚类、异常和模型对比，并新增区县覆盖、来源数和异常率。登录页技术口径已改为 scikit-learn、DeepSeek、ECharts/Recharts，同时移除未实现的 SSO 和忘记密码入口。



图 3-2 Dashboard 真实业务库页面

第 4 章 数据获取与实现

4.1 数据源与采集边界

系统实现房天下、安居客移动端和链家等爬虫适配，其中房天下当前可直接返回普通 HTML，作为默认小规模采集源；安居客移动端页面结构存在波动；链家需要 Cookie，仅作为实验来源。采集器遵循确定性程序控制，Agent 不负责打开网页或绕过验证码。默认并发为 3—5，请求间隔 1—3 秒，页数和区县均由任务参数限制。

BaseCrawler 统一请求、限速和错误包装，具体爬虫只实现 URL 构造与页面解析。CrawlerRegistry 根据 source 选择实现，CrawlService 创建任务、运行分片、写日志并调用 ListingService 入库。页面被登录、验证码或反爬网关拦截时，记录明确错误而不是把空页面当成成功。失败页不会导致 Flask 服务崩溃。

4.2 多线程任务

任务按照区县和页码拆分为独立单元，ThreadPoolExecutor 控制并发。每个 future 返回解析条数或错误信息，主线程汇总 total_pages、success_pages、failed_pages、inserted_count、updated_count、unchanged_count 和 snapshot_count。任务最终根据失败情况进入 success、partial_failed 或 failed。

多线程的目的不是压榨目标网站，而是在低并发下减少区县之间的串行等待。实际收口采集使用并发 2、每区 1 页。第一轮 6 个区县全部成功，解析 360 条并新增 360 条；第二轮相同范围有 3 页成功、3 页被网关拦截，仍解析 180 条，其中新增 27 条、未变化 153 条，证明任务能在部分失败时保留有效结果。



图 4-1 房天下增量任务与失败日志页面

4.3 增量更新实现

入库前先进行字段清洗并计算 `fingerprint`。若 `source + fingerprint` 不存在，则插入 `listings` 并写第一条 `snapshot`；若存在且价格未变化，则只更新 `last_seen_at` 和必要的可补全字段；若价格变化，则更新 `listings` 当前价格并追加 `snapshot`。该流程由 `ListingService.upsert_listing` 集中实现，采集器和冷启动导入脚本复用同一规则。

当前主表 122,316 条，快照表 122,317 条，恰好多出 1 条，且数据库中有 1 套房源存在多次快照。任务 #3 的真实记录为新增 30、价格更新 1、未变化 29、快照新增 1；任务 #6 则证明重复采集 153 条时主表不重复增长。另有 `verify_incremental_snapshot.py` 可创建临时样本，依次验证插入、重复和价格变化，默认完成后清理。

增量 upsert 核心逻辑（示意）

```
if listing is None:
    insert_listing(cleaned)
    append_snapshot(cleaned)
elif price_changed(listing, cleaned):
    update_current_price(listing, cleaned)
    append_snapshot(cleaned)
else:
    listing.last_seen_at = now
```

4.4 调度与当前边界

`APScheduler` 可注册定期质量报告和定期增量采集两个 `interval` 任务，时区为 `Asia/Shanghai`，并通过 `max_instances=1` 防止同一任务并发重入。系统还提供 `/api/scheduler/status`、`/run-quality-report` 和 `/run-incremental-crawl`，用于查看注册状态与手动触发。测试环境和非部署阶段默认关闭常驻调度，属于预期行为。

服务器常驻调度尚未作为已完成上线能力。后续部署时才会设置 `SCHEDULER_ENABLED=true`、明确区县与页数、通过 `systemd` 保证进程重启，并观察至少一个完整周期。当前不启用“连续 N 次未出现即 `inactive`”，因为每次只采有限页面，未出现可能只是本轮未覆盖，贸然标记会引入错误状态。

第 5 章 数据整理（清洗与存储）实现

5.1 字段标准化

采集结果先映射到统一 schema，再进入数据库。总价提取数字并统一为万元，单价统一为元/平方米，面积统一为平方米；layout 原文保留并解析 rooms、halls；floor_text 归一为 low、mid、high 或 unknown；build_year 提取年份并派生 house_age；district 使用重庆区县字典映射；link 保留原始链接并参与来源追踪。

异常值不直接删除。总价小于 5 万元或大于 5000 万元、单价小于 1000 或大于 100000 元/平方米、面积小于 10 或大于 500 平方米、建成年份超出合理范围时标记 abnormal。这样既能避免极值污染训练，也能保留原始记录供页面复核和规则调整。

表 5-1 核心清洗规则

字段	清洗规则	异常处理
total_price	提取数字，单位万元	<5 或>5000 标记
unit_price	提取数字，单位元/m²	<1000 或>100000 标记
area	提取数字，单位m²	<10 或>500 标记
layout	保留原文并解析室厅	解析失败保留原文
floor	归一 low/mid/high	无法判断为 unknown
build_year	提取年份并计算楼龄	越界标记异常
district	重庆区县标准映射	失败进入待复核

5.2 冷启动导入

旧项目中的 SQLite/CSV 只作为一次性冷启动来源。import_legacy_sqlite_to_mysql.py 读取旧表，进行字段映射、清洗和批量 upsert，并把来源标为 anjuke_legacy 或 lianjia_legacy。导入完成后，Web 查询、图表、分析和 Agent 均只访问 MySQL，不再把 SQLite 作为运行数据库。

当前有效数据中 anjuke_legacy 为 118,661 条，lianjia_legacy 为 3,116 条，fang 为 539 条。该分布说明系统的数据规模主要来自旧库基线，新系统采集用于证明标准链路和增

量能力。说明书和答辩必须如实展示这一点，不能把 12 万条都归功于当前爬虫。

5.3 数据质量报告

QualityService 从完整性、极值、低质量样本、可分析记录和快照数量等维度生成报告。最新报告 #3 的 `total_count` 与业务库一致，为 122,316 条；`analysis_ready_count` 为 122,288 条；极值记录 28 条，低质量记录 3 条，快照 122,317 条。报告已不再停留在旧的 121,837 条。

平均质量分为 100 不代表数据绝对无误，它反映当前规则下必填字段完整度较高。极值检测和模型训练过滤仍然独立执行，前端也展示异常列表。质量分的价值在于形成可复核的运行快照，而不是用单一分数掩盖来源偏差、时间偏差和页面解析误差。

5.4 数据规模与分布

区县样本量分布不均衡，沙坪坝、南岸、渝北、江北和九龙坡样本较多，部分远郊区县样本较少。如果直接按更新时间取最近 1000 条，样本会集中在最后导入或最后采集的几个区县，导致模型结论并不代表重庆整体。数据层因此保留区县和来源字段，分析层再按区县进行分层抽样。

趋势图只使用 `listings` 的 `first_seen_at` 与 `listing_snapshots` 的 `snapshot_at` 等真实时间字段。当前时间跨度主要来自 2025 年旧库和 2026 年系统快照，不能伪造多年趋势。页面中的趋势应理解为现有快照观察，不应外推为长期房地产周期。

第 6 章 数据分析、可视化与智能问数实现

6.1 抽样策略修正

早期分析服务按 `updated_at` 倒序取最近 1000 条，实际只覆盖 4 个区县，虽然运行速度快，却会把局部数据误当作全重庆样本。收口阶段将默认样本扩大到 5000 条，并实现 `district_stratified_deterministic`：每个有效区县至少保留一个样本，其余名额按区县可用样本量比例分配，区县内部使用固定 CRC32 顺序抽样。

最新任务 #9 的 `sample_count` 为 5000，覆盖 38 个区县和 3 类来源；其中 `anjike_legacy` 4852 条、`lianjia_legacy` 125 条、`fang` 23 条。确定性顺序使同一数据集重复训

练得到可复核样本，分层覆盖则避免少数区县完全缺失。来源仍以旧库为主，这是模型解释时必须披露的限制。

6.2 回归模型

预测目标为挂牌单价，输入特征包含面积、总价辅助字段、房龄、室厅、楼层等级、区县、朝向、装修和来源等。训练前排除强异常和关键字段不足样本，并将类别字段编码。系统比较 RandomForestRegressor、GradientBoostingRegressor、HistGradientBoostingRegressor 等候选模型，以测试集 R^2 排序并保存全部候选结果，避免只展示一个模型而没有对照。

最新最优模型为 RandomForestRegressor 集成树。5,000 条源样本中 4,616 条用于回归建模，训练集 3692 条，测试集 924 条；MAE=1166.21 元/平方米，RMSE=1598.61 元/平方米， $R^2=0.7105$ ，MAPE=13.95%。该结果可用于解释特征和提供粗粒度辅助估价，但误差仍然明显，不能称为精准预测。

特征重要性显示房龄贡献最高，区县样本量、楼层等级、朝向、来源和部分区县哑变量也有影响。这里的重要性描述的是模型在当前样本中的分裂贡献，不等于因果关系。房龄重要可能同时反映地段、建筑类型和旧库字段分布，后续需要更均衡的新采集样本和更细的地理特征验证。

6.3 KMeans 市场分层

聚类使用挂牌单价、面积、总价、房龄等连续特征标准化后执行 KMeans，并比较候选 k。最新任务选择 4 类，轮廓系数为 0.2848。该值低于早期 4 区县偏置样本的 0.7547，说明覆盖 38 个区县后真实市场结构更连续、类间边界更复杂。指标下降并非系统退化，而是抽样更有代表性后对原先乐观结果的纠正。

聚类结果用于形成样本画像，例如低总价小面积、刚需主流、改善型大面积和高单价核心区等相对分层。每一类都保存样本量、均价、面积和房龄等统计。聚类标签不能直接解释为房屋优劣，也不能替代人工估值；它更适合帮助 Dashboard 筛选和答辩时说明市场内部结构。

6.4 异常检测

早期 IsolationForest 在 1000 条样本上识别 369 条异常，36.9%的比例明显过高。修正

后污染率按样本规模限制在 2%—8%，当前 5000 条样本取 2%；同时计算区县中位数偏离率与 Z 分数。最终异常由模型孤立样本和强规则共同确认，并为每条记录保存偏离率、Z 分数和命中规则。

最新结果共识别 123 条异常，占 2.46%；其中模型异常 100 条，强规则命中 47 条。这个比例适合人工复核，不会让异常列表淹没正常房源。异常数据默认不物理删除，只在模型训练中过滤。

6.5 可视化实现

Dashboard 的 KPI 直接来自 `/api/overview`，区县排行、价格分布、快照趋势、面积—价格散点和户型分布分别由图表接口返回 JSON。重庆地图加载本地 GeoJSON，支持均价、样本量和质量分切换。房源页支持筛选、分页、详情和 CSV 导出；采集页展示数据源、任务进度与页级日志；质量页展示报告；分析页展示模型证据。

真实页面验证使用 Edge 通道的 CLI Playwright。检查内容包括 URL 与标题、主要 DOM 文本、框架错误覆盖层、console warning/error 和截图。Dashboard 显示 122,316 套、38 个区县和 122,317 条快照；采集页显示 780 条累计解析与部分失败日志；分析页显示 5,000 条样本、38 区县、 R^2 0.7105 和异常率 2.46%。三页均无相关控制台错误。




图 6-1 最新分析任务与模型指标页面

6.6 DeepSeek Agent

AgentService 先识别问题意图，再由 ToolRegistry 调用 `query_market_stats`、`get_chart_series`、`get_crawl_status`、`run_incremental_crawl`、`run_analysis_job`、`get_model_result` 或 `generate_report`。只读工具查询服务层聚合结果，写工具只创建受控任务或报告。Agent 不获取数据库连接，不接受任意 SQL，也不能绕过采集规则。

真实连接测试已改为向 DeepSeek 发起轻量请求，不再仅检查是否配置密钥。首次 `max_tokens=8` 被推理内容消耗后，将预算调整为 64 并兼容 `reasoning_content`。数据库现有 25 条工具调用和 5 份报告，最新报告 #5 同时包含 market 与 model 两类证据；报告 PDF 已导出并通过页数、标题和文本结构检查。

模型问答工具返回前 10 个特征重要性和聚类画像摘要，解决了早期为压缩日志而删掉特征正文的问题。回答中的房源数、均价、MAE、RMSE 和 R^2 均来自工具 JSON。若工具没有数据，系统提示先执行采集或分析任务，而不是编造具体数值。



图 6-2 Agent 工具调用与报告验收脚本输出快照

第 7 章 测试、问题解决、总结与展望

7.1 测试与性能

后端测试覆盖健康检查、鉴权、房源筛选、Dashboard、采集、质量、调度、分析、Agent 和系统设置。收口后执行 `python -m compileall Backend` 成功，`python -m pytest Backend/tests -q` 返回 34 passed；前端 `npm run build` 成功，Vite 转换 2944 个模块。构建产物主 JavaScript 约 2.1 MB，存在分包建议，但不影响本地课程演示，页面懒加载列为后续优化。

常用图表接口在真实 12 万条业务库上进行一次本机冷调用测试，overview 为 1019.58 ms，district-price 为 253.42 ms，price-distribution 为 306.67 ms，price-trend 为 98.10 ms，500 点散点为 25.92 ms，户型分布为 162.93 ms，均低于 2 秒目标。该结果只代表当前电脑与数据库状态，不宣称等同于公网部署性能。

表 7-1 非部署阶段验收结果

验收项	命令/路径	结果
语法检查	<code>python -m compileall Backend</code>	通过
后端测试	<code>python -m pytest Backend/tests -q</code>	34 passed
前端构建	<code>npm run build</code>	通过，2.1 MB 提示

验收项	命令/路径	结果
增量验证	python scripts/verify_incremental_snapshot.py	脚本可复用
接口性能	/api/overview 与 /api/charts/*	全部 <2 秒
浏览器验证	CLI Playwright + Edge	三核心页通过

7.2 关键问题与解决过程

问题一是模型样本偏差。表面上 1000 条足够训练，实际按更新时间取样只覆盖 4 个区县，导致较高的聚类轮廓系数和不可靠的全市结论。解决方法不是简单扩大 limit，而是按区县分层分配名额，并记录抽样策略、区县覆盖和来源分布。修正后回归 R^2 提升到 0.7105，但聚类轮廓系数降到 0.2848，更符合全市数据的复杂性。

问题二是异常比例过高。单独使用 IsolationForest 且污染率设置不合理，会把大量正常波动列为异常。解决方法是收紧污染率、引入区县中位数偏离和 Z 分数，并输出判定理由。异常率降到 2.46%，更适合复核。问题三是外部页面波动。系统不重复强试，而是把验证码或网关拦截记录为 WARN，使任务部分失败但不丢失成功页。

问题四是 Agent 连接测试过于形式化。只判断密钥存在不能证明接口可用，因此改为真实轻量请求；又针对推理模型可能把少量 token 用于 reasoning_content 的情况提高预算并兼容诊断预览。问题五是文档与实现脱节，旧稿仍写原生 JS、未来功能和部署完成态。本次以业务库、测试和页面证据为准统一重写，部署只作为后续方案。

7.3 专业能力与项目管理总结

本项目训练了从需求拆解到验证交付的完整能力。开发过程中需要同时理解网页解析、数据建模、SQL 聚合、后端分层、前端状态、机器学习指标和大模型工具调用。相比只完成单个算法实验，系统化工作要求每个数字都能追溯到数据库或模型结果，每个“已完成”都要有命令、接口或页面证据。

在项目管理上，采用 GOAL 任务标准把目标、产物、验收和边界写清楚，避免一次性重构整个系统。遇到浏览器、网页和模型接口问题时遵循失败次数与退出规则，不在同一路径反复消耗。对旧数据、新采集、模型边界和部署状态保持如实表述，是课程设计中比堆砌技术名词更重要的工程诚信。

团队协作方面，本文只记录本人张浩博实际承担并可核验的需求梳理、数据链路、分析建模、前后端联调、测试和材料收口工作，不虚构未确认成员的分工。若最终以小组提交，可由组长依据真实提交记录补充其他成员的任务和贡献。

7.4 当前不足

第一，新系统标准采集数据只有 539 条，模型样本仍以旧库为主；需要长期低频采集提高新数据占比。第二，时间快照跨度有限，趋势分析只能描述现有采集窗口。第三，质量分对完整性较敏感，但对语义错误、重复小区名称和平台偏差的度量仍较粗。第四，KMeans 轮廓系数仅 0.2848，说明市场分层边界不强，不能把聚类包装成确定分类。

第五，前端主包约 2.1 MB，后续可按路由懒加载图表。第六，Agent 初始页面不自动恢复数据库中的历史会话，真实报告需要在当前会话生成后展示；数据库证据和 PDF 导出已完成，但会话持久化 UI 可继续完善。第七，调度器尚未在服务器连续运行，部署、HTTPS、日志轮转、备份恢复和公网性能均未验收。

7.5 可复现性与工程细节复盘

7.5.1 查询设计与索引

房源主表的数据量达到十万级后，页面性能不再只取决于前端渲染，数据库筛选和聚合方式更加关键。listings 对 district、total_price 和 updated_at 建立索引，source 与 fingerprint 使用联合唯一约束。房源分页查询先组合区县、价格、面积和关键词条件，再执行 count 与分页结果查询；图表接口只返回绘图需要的聚合字段或有限散点，不把整表序列化给浏览器。

overview 需要同时统计有效房源、均价、总价、完整率、区县数和快照数，冷调用约 1 秒，是常用接口中耗时最高的一项。区县排行、价格分布和户型分布使用 GROUP BY，散点图通过 limit 控制返回量，趋势图只聚合快照月份。当前指标已经满足课程演示，但如果未来数据持续增长，可以增加按日预聚合表、短时缓存和更细的联合索引，并用 EXPLAIN 验证执行计划，而不是过早引入复杂中间件。

7.5.2 配置、鉴权与秘密信息

配置分为代码默认值、.env 环境变量和 system_settings 数据库设置三层。开发环境可以使用默认端口，但数据库密码、SECRET_KEY 和 DeepSeek API Key 不应写进源码。设置接口返回时只显示掩码，更新密钥时识别占位掩码并避免覆盖真实值。测试环境强制关闭

DeepSeek 与调度器，防止自动化测试产生外部费用或修改业务任务。

登录模块定位为课程演示的本地管理员鉴权，Token 有过期时间，前端 API 客户端统一附加 Authorization 头。系统没有实现学校 SSO、找回密码、用户注册和多角色权限，因此登录页已经移除相关入口，文档也不把它描述为企业级权限系统。若后续公网部署，应更换默认账号密码、启用 HTTPS、限制跨域来源，并将鉴权状态写入安全日志。

7.5.3 测试隔离与故障注入

后端测试使用 `real_estate_test`，`conftest` 在测试应用中关闭鉴权、调度器和 DeepSeek，保证测试不会污染 122,316 条业务数据。采集器测试通过本地 HTML 或模拟响应验证解析，任务测试检查成功、失败和部分失败状态；分析测试使用小样本验证分层覆盖、指标字段与异常率上限；Agent 测试验证工具选择、证据裁剪和特征重要性保留。

真实故障并不都适合在单元测试中模拟，因此收口阶段还保留运行证据。房天下第二轮出现三页网关拦截，任务仍保存三页成功结果并以 `partial_failed` 结束；Playwright 默认浏览器缺失时切换到已安装 Edge，页面引用失效或交互没有推进时按退出规则停止，而不是在多个浏览器工具之间循环。这些记录体现了系统对外部不确定性的处理方式。

7.5.4 模型复现与证据字段

模型结果不仅保存 MAE、RMSE、 R^2 等指标，还保存抽样策略、请求样本上限、实际样本数、区县分布、来源分布和固定种子。回归候选模型保存排名与测试指标，聚类保存候选 k 和画像，异常检测保存污染率、阈值、模型异常数与强规则数。这样即使页面只展示摘要，也可以从 `model_results.evidence_json` 还原结论条件。

固定 CRC32 顺序抽样的价值是让同一数据版本能够重复得到相同样本，便于比较代码改动前后的结果；它不意味着样本天然随机，也不能消除旧库来源偏差。为了进一步提高科研严谨性，后续可以保存数据版本哈希、训练参数、scikit-learn 版本和模型文件，并采用按区县分组的交叉验证，检查模型是否只记住样本量大的区域。

7.5.5 文档证据自动化与数据伦理

正式材料中的数字来自 `export_acceptance_evidence.py` 导出的 JSON，而不是手工复制旧结论。脚本读取业务库的房源、来源、快照、质量、模型、采集和 Agent 表，并执行常用接口耗时测试；`build_submission_documents.py` 再使用学院模板生成说明书、安装说明、答辩清单和日志。数据变化后可重新运行两条命令刷新材料，减少文档与系统不一致。

自动生成不等于可以省略人工审查。文档明确区分挂牌价与成交价、旧库与新采集、代

码支持与服务器常驻、模型相关性与因果解释。网页采集遵守低并发和停止规则，验证码或网关出现时记录失败，不尝试绕过；房源数据用于课程研究，不在文档中展示个人联系方式。上述边界既是技术限制，也是数据工程必须承担的伦理责任。

7.5.6 前端状态与可用性设计

前端页面不是把接口 JSON 直接堆在屏幕上，而是针对不同任务设计状态。Dashboard 区分加载、成功和刷新；房源表在筛选变化时回到第一页，避免页码超出结果范围；采集任务用进度条、状态标签和日志等级区分正常完成、部分失败与失败；分析页只有在最新任务成功且结果齐全时显示指标，缺少结果时给出重新训练入口。

页面视觉采用深蓝导航、白色卡片和浅灰背景，数值单位与标签分离，避免把挂牌单价和总价混在同一尺度。图表标题说明数据口径，地图支持均价、样本量和质量切换。浏览器验证重点检查 1440×1000 桌面答辩视口中的对齐、溢出、图表渲染、favicon 和控制台错误；移动端不是本轮主要演示场景，因此只保留响应式基础能力，不宣称完成全面移动端适配。

7.5.7 数据血缘与口径核验

每条房源通过 source、source_listing_id、link、first_seen_at 和 last_seen_at 保留基本血缘。冷启动导入脚本不会把 legacy 来源改写成 fang；采集任务的 task_id 可以关联快照；质量报告保存生成时间；模型结果关联 analysis_job；Agent 工具调用保存 session_id、question、tool_name、args、result 和 duration。由此可以从页面结论逐层追溯到服务结果和数据库记录。

口径核验尤其关注区县名称和时间字段。旧库中可能出现带“区”与不带“区”的名称，系统在分析证据中保留真实分布，前端展示时做可读映射但不伪造合并结果。快照趋势按真实月份聚合，若某个月没有采集就不补零生成虚假曲线。模型目标始终是 unit_price，报告中的平均总价与平均单价分别注明万元和元/平方米。

7.5.8 答辩可解释性设计

答辩演示按照“问题—系统—证据—边界”组织，而不是逐页介绍技术名词。先说明公开挂牌数据存在来源分散、重复和变化问题，再展示 MySQL 规模与来源结构；随后用采集任务证明失败可追踪、重复不重复入库和价格变化进快照；再用 Dashboard 与模型页说明分析结论；最后用 Agent 工具记录说明智能问数没有绕开数据治理。

对指标的解释坚持保守口径。 $R^2 0.7105$ 表明模型解释了测试集约 71% 的波动，但 MAE 仍有 1166.21 元/平方米；轮廓系数 0.2848 表明市场分层只是辅助画像；异常率 2.46% 表

示待复核样本，不表示错误房源；12 万条规模主要来自旧库冷启动，新系统采集为 539 条。把这些限制主动讲清楚，比只展示最好看的数字更能体现数据分析的可信度。

7.5.9 维护、备份与版本管理

运行维护需要同时保护代码、配置和数据。代码通过 Git 记录版本，.env、数据库密码、API Key、运行日志和临时截图不应提交；数据库应定期使用 mysqldump 生成带日期的备份，并至少进行一次恢复演练。采集、质量和分析任务都保留 created_at、started_at 与 finished_at，便于发现卡死任务和比较不同版本的运行结果。

本轮只在本机完成业务库验证，没有执行生产备份和恢复，因此文档不把备份脚本写成已上线能力。后续部署时应增加日志轮转、磁盘空间告警、数据库最小权限账号和备份保留周期；模型与报告需要关联代码版本和数据版本。只有备份文件能够实际恢复、服务重启能够自动拉起，维护方案才算完成，而不是仅存在一段部署命令。

7.6 后续部署方案

部署阶段计划使用阿里云轻量服务器或 ECS，MySQL 8.x 作为数据库，Gunicorn 承载 Flask，Nginx 提供静态文件和反向代理，systemd 管理进程，环境变量保存数据库连接与 DeepSeek 密钥。上线后先导入冷启动数据，再执行小规模健康检查与增量任务，最后开启质量报告和增量采集调度。

部署验收必须包含公网首页和 API 可访问、服务器重启后服务自动恢复、Nginx 与 Gunicorn 日志正常、数据库备份可恢复、敏感信息未提交。由于本轮明确暂缓部署，以上内容仅为方案，不作为已经上线的事实。

7.7 结论

项目已经完成学院要求的核心非部署闭环：超过 5 万条的 MySQL 数据底座、字段清洗、增量 upsert 与快照、多线程任务和失败日志、Web 多维可视化、回归聚类异常检测、DeepSeek 工具调用与报告、自动化测试和正式材料。最重要的收口改进是把模型样本扩展为覆盖 38 个区县的分层样本，并把数据来源、模型误差、异常比例和未完成部署如实写入证据。

系统当前适合作为课程设计原型和后续科研工程基础，而不是商业房价估值产品。只要继续积累新系统快照、完善会话持久化、优化前端分包并完成服务器部署，就可以进一步形

成可长期运行、可公开演示的重庆二手房挂牌价智能分析平台。